Введение в Spark

Дмитрий Киселёв

24.10.2020

План лекции

- Что такое Spark?
- RDD API
- Выполнение кода на Spark
- DataFrame API
- Когда применять?

Обо мне

- Исследователь в AIRI, Аспирант ФКН НИУ ВШЭ
  - Изучаю применение GNN к различным прикладным задачам (рексистемы, биоинформатика, поиск аномалий и тд)

- Контакты: dkiseleff@gmail.com, tg: dkiselev

Apache spark

- Apache Spark is a unified analytics engine for large-scale data processing.

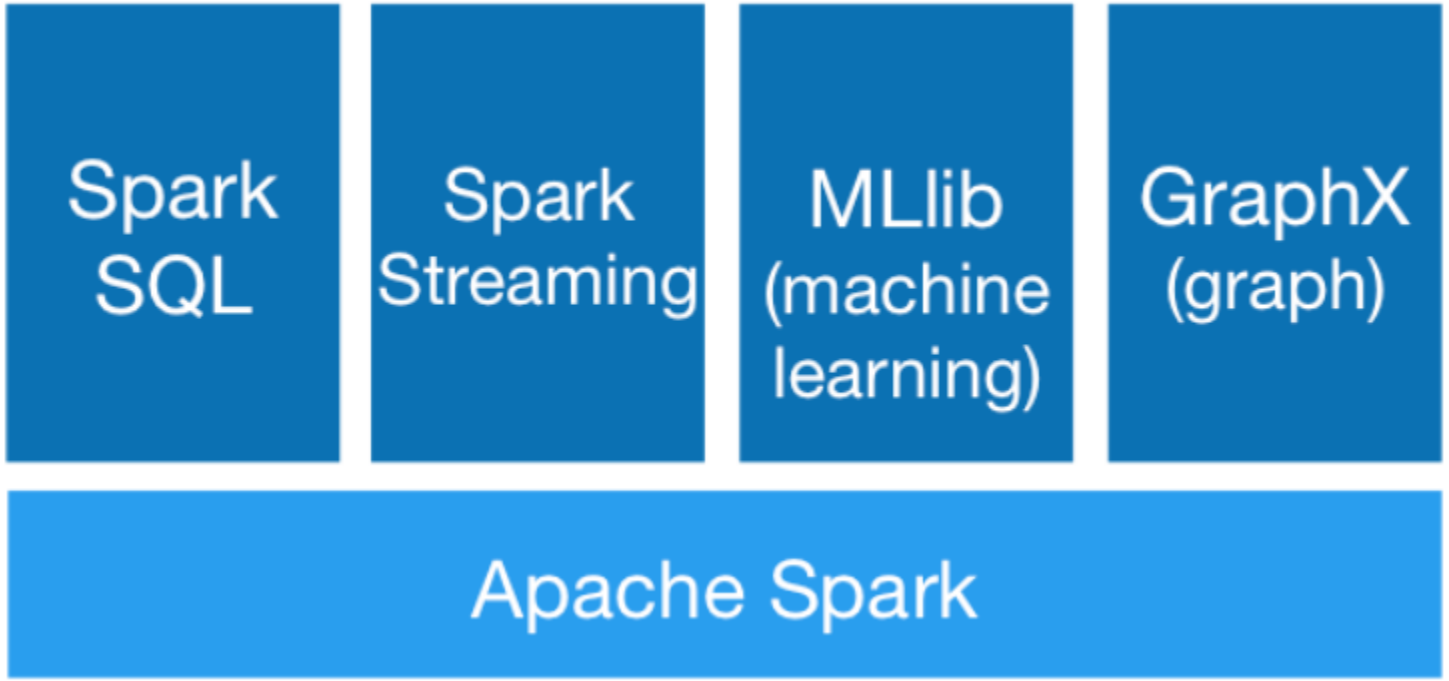

Link: https://spark.apache.org/

Зачем?

- Классический MapReduce работает медленно
  - Мапперы пишут данные на диск редьюсера
  - Нет оптимизации запросов
- Spark работает значительно быстрее
  - Хранение промежуточных результатов в памяти
  - Восстанавливаемые распределенные наборы данных (RDD)
  - Представление заданий в виде направленных ацикличных графов (DAG)
- Не привязан к HDFS
- Не привязан к менеджерам ресурсов

Resilient Distributed Dataset

- Распределенная коллекция (данные хранятся в партициях)
- Неизменяемый (Immutable)
- Хранит информацию о родителях и цепочке вычислений
- Каждый элемент – сериализуемый объект
- Ленивые трансформации (transformations) над RDD
  - map, join, …
- Действия (actions) над RDD – запускают граф вычислений (Job)
  - save, collect, …

Зависимость между RDD

- Узкая (Narrow Dependency)
  - Каждая партиция родительского RDD поступает на вход ровно одной дочерней
- Широкая (Wide Dependency)
  - Партиция родительского RDD может поступать сразу в несколько дочерних партиций (нужен shuffle)

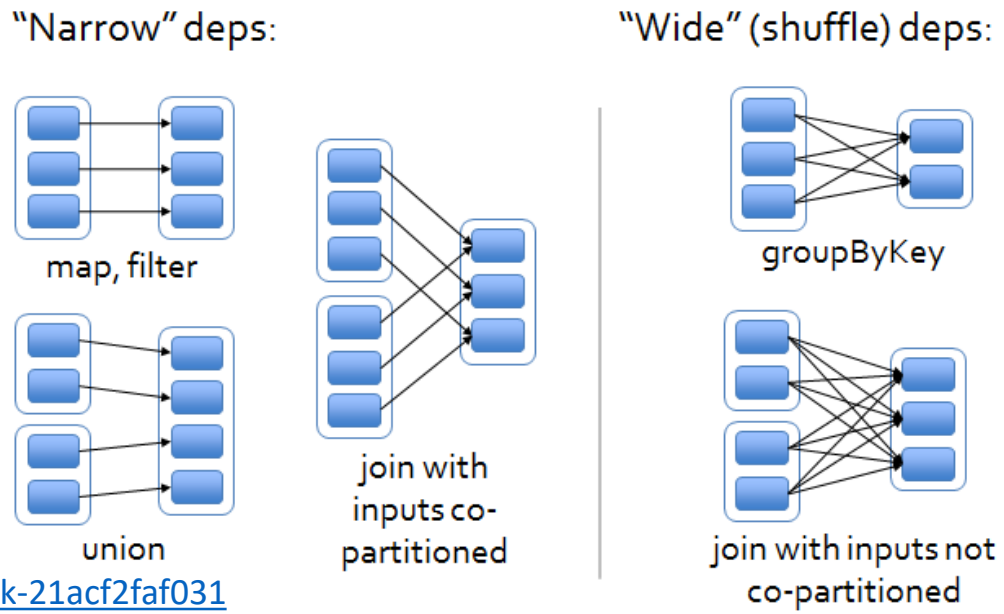

Link: https://medium.com/@dvcanton/wide-and-narrow-dependencies-in-apache-spark-21acf2faf031

Пример

- Хотим посчитать Tf-Idf для набора текстовых комментариев
  1. Читаем данные (операция read)
  2. Токенизируем текст (трансформация map, узкая)
  3. Считаем частоты слов внутри предложений (map, узкая)
  4. Уплощаем структуру (трансформация flatmap, узкая)
  5. Считаем счетчики по словам (агрегация: reduce by key , широкая)
  6. Джойним счетчики на оригинальные слова (join, широкая)
  7. Считаем Tf-Idf (map, узкая)
  8. Агрегируем все в один вектор по наблюдению (reduce by key, широкая)
  9. Сохраняем (действие save, вызывает исполнение)

Физический план

- Физический план представляет собой DAG
- Физический план описывает выполнение задания (Job)
- Физический план состоит из этапов (Stages)
- Этапы состоят из задач (Tasks) над конкретным RDD

Построение физического плана

- Вызов операции действия (Action)
- Построение логического плана
  - Строится из графа зависимостей RDD
- Разделение логического плана на задачи (Tasks)
- Конвейеризация задач (Pipelining) в этапы (Stages)
  - Spark объединяет узко зависимые RDD в один этап

Пример WordCount

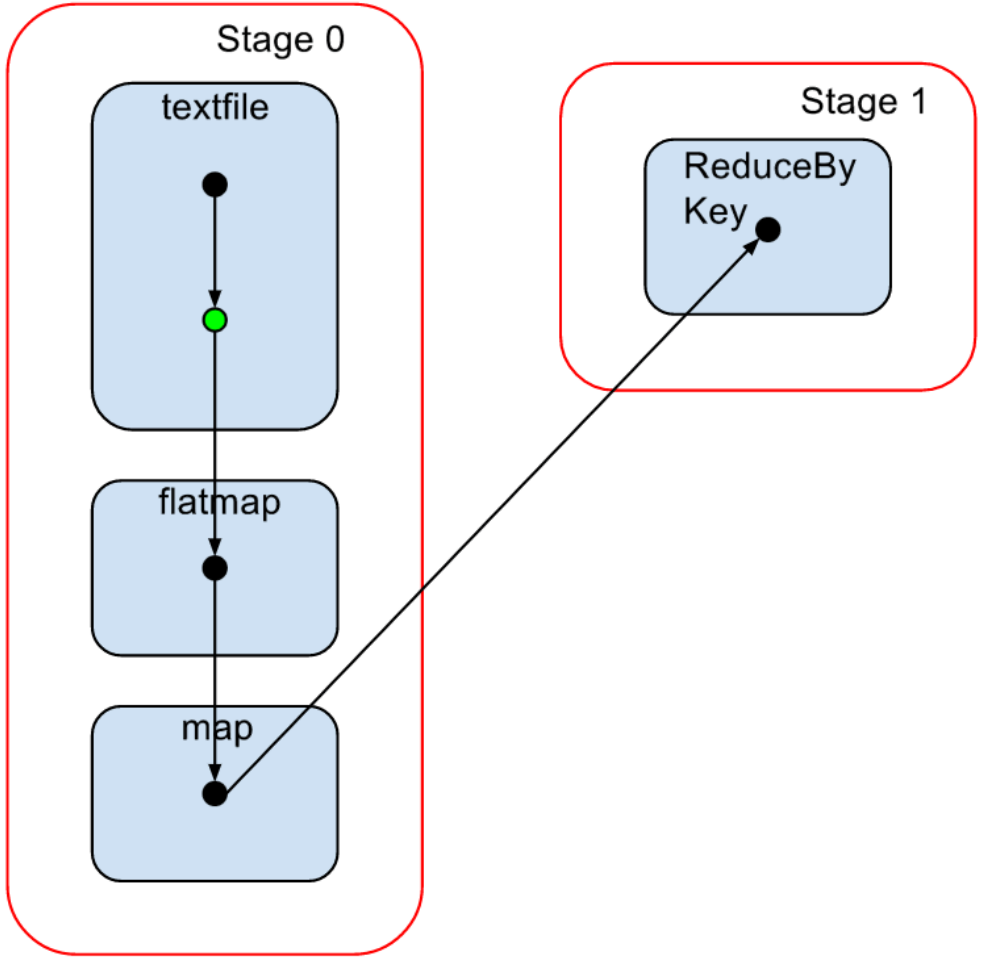

Исполнение кода на Spark

- Driver
  - Инициализирует приложение
  - Запрашивает ресурсы
  - Формирует физический план
  - Передает сериализованный код задач
  - Отслеживает их выполнение
  - Завершает приложение
  - Запрашивает освобождение ресурсов
- Executors
  - Получает от драйвера конкретную задачу
  - Отправляет статус выполнения на драйвер
  - Завершает выполнение по команде драйвера

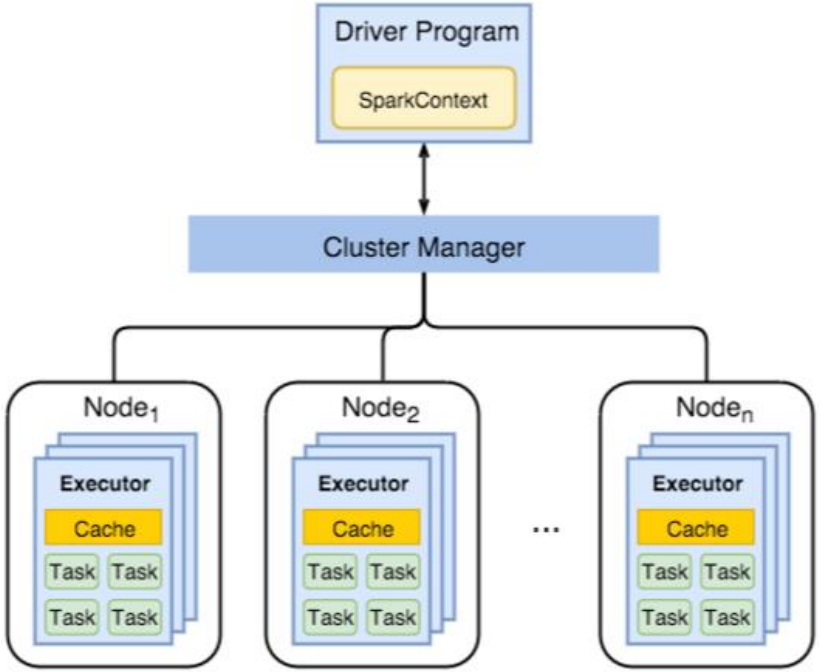

DataFrame API

- Работает с таблицами (DataFrame)
  - Таблицы имеют схему (колонки и их типы)
- Ограничен SQL операторами
  - Sql операции генерируют java код (ок использовать в PySpark)
  - Но можно делать user-defined functions
- Единое API для всех типов данных

- Знание о типах позволяют делать оптимизацию

Оптимизация запросов (Catalyst)

- Catalyst преобразует синтаксическое дерево в физический план выполнения
- Catalyst состоит из четырех этапов
  - Анализ – проверяет метаданные таблиц (колонки, типы)
  - Логическая оптимизация
    - constant folding (считаем константы заранее и заменяем везде)
    - predicate pushdown (берем только нужные куски данных)
    - другие
  - Физическое планирование – cost-based оптимизация
  - Генерация кода

Joins

- Shuffle join
  - Бьем все по ключу и кладем в одну партицию (Map + Shuffle)
  - Джойним по хэшам (Hash join)
  - Или слиянием (Merge join)
- Broadcast joint
  - Если таблица достаточно маленькая, то можем сделать по ней хэш таблицу и передать на все мапперы
- Spark делает для них CBO

Когда применять Spark?

- Когда много данных
- Когда много источников
- Когда нужна гибкость

Workshop

Домашнее задание

- По данным TripAdvisor hotel reviews посчитать Tf-Idf с помощью Spark DataFrame / Dataset API без использования Spark ML
- Этапы
  - Привести все к одному регистру
  - Удалить все спецсимволы
  - Посчитать частоту слова в предложении
  - Посчитать количество документов со словом
  - Взять только 100 самых встречаемых
  - Сджойнить две полученные таблички и посчитать Tf-Idf (только для слов из предыдущего пункта)
  - Запайвотить табличку